

Московский авиационный институт
(национальный исследовательский университет)

Факультет информационных технологий и прикладной
математики

Кафедра вычислительной математики и программирования

Курсовой проект по курсу «Дискретный анализ»
«Алгоритм LZ77»

Студент: Д. М. Чистяков
Преподаватель: С. А. Сорокин
Группа: М8О-306Б-20
Дата:
Оценка:
Подпись:

Москва, 2023

1 Условие

Задача:

1. **Вариант LZ77** Реализуйте алгоритм LZ77. Без окна, поиск производится по всему просмотренному ранее тексту.
2. Первый тип: текст состоит только из малых латинских букв. В ответ на него вам нужно вывести тройки, которыми будет закодирован данный текст.
3. Второй тип: вам даны тройки ($\langle \text{offset}, \text{len}, \text{char} \rangle$) в которые был сжат текст из малых латинских букв, вам нужно его разжать.

2 Метод решения

Был создан класс *LZ77*, в котором реализованы методы для кодирования и декодирования текста. Метод *LZ77::Encode* принимает на вход строку и возвращает вектор троек, алгоритм использует наивный поиск строки в буфере и имеет итоговую сложность $O(n^3)$. Метод *LZ77::Decode* принимает на вход вектор троек и возвращает декодированную строку, работает за $O(n)$.

3 Исходный код

```
1 | #include <iostream>
2 | #include <vector>
3 |
4 | class LZ77 {
5 |     public:
6 |     struct Node {
7 |         int offset;
8 |         int size;
9 |         char symbol;
10 | };
11 |
12 | static inline const char EOM = ' ';
13 |
14 | static void Encode(std::string& input, std::vector<LZ77::Node>& output) {
15 |     int pos = 0;
16 |     while (pos < input.size()) {
17 |         LZ77::Node n = {0, 0, input[pos]};
18 |         for (int i = 0; i < pos; i++) {
19 |             if (input[i] != input[pos]) {
20 |                 continue;
21 |             }
22 |             int size = 1;
23 |             while (pos + size < input.size() && input[i + size] == input[pos + size]) {
24 |                 size++;
25 |             }
26 |             if (size >= n.size) {
27 |                 n.size = size;
28 |                 n.offset = pos - i;
29 |             }
30 |         }
31 |         if (pos + n.size >= input.size()) {
32 |             n.symbol = LZ77::EOM;
33 |         }
34 |         else {
35 |             n.symbol = input[pos + n.size];
36 |         }
37 |         output.push_back(n);
38 |         pos += n.size + 1;
39 |     }
40 | }
41 |
42 | static void Decode(std::vector<LZ77::Node>& input, std::string& output) {
43 |     for (LZ77::Node& n : input) {
44 |         if (n.offset != 0) {
45 |             int pos = output.size();
46 |             for(int i = 0; i < n.size; i++) {
47 |                 output.push_back(output[pos - n.offset + i]);
```

```

48     }
49 }
50
51     if (n.symbol != EOM) {
52         output.push_back(n.symbol);
53     }
54 }
55 }
56 };
57
58 int main() {
59     std::ios::sync_with_stdio(false);
60     std::cin.tie(0);
61     std::cout.tie(0);
62     std::string cmd;
63     std::cin >> cmd;
64
65     if (cmd == "compress") {
66         std::string text;
67         std::cin >> text;
68         std::vector<LZ77::Node> res;
69         LZ77::Encode(text, res);
70         for (LZ77::Node& n : res) {
71             std::cout << n.offset << " " << n.size << " " << n.symbol << "\n";
72         }
73     }
74
75     if (cmd == "decompress") {
76         std::vector<LZ77::Node> code;
77         LZ77::Node n;
78         while (std::cin >> n.offset >> n.size) {
79             if (!(std::cin >> n.symbol)) {
80                 n.symbol = LZ77::EOM;
81             }
82             code.push_back(n);
83         }
84
85         std::string res;
86         LZ77::Decode(code, res);
87
88         std::cout << res << "\n";
89     }
90     return 0;
91 }

```

4 Консоль

```
den@vbox: ~/Документы/DA/CP$ g++ cp.cpp
den@vbox: ~/Документы/DA/CP$ ./a.out
compress
abracadabra
0 0 a
0 0 b
0 0 r
3 1 c
2 1 d
7 4
den@vbox: ~/Документы/DA/CP$ ./a.out
decompress
0 0 a
0 0 b
0 0 r
3 1 c
2 1 d
7 4
abracadabra
```

5 Выводы

В результате выполнения курсового проекта я реализовал алгоритм LZ77. Моя реализация простая и использует наивный алгоритм поиска подстроки, но алгоритм можно улучшить используя суффиксное дерево, тогда сложность кодирования станет $O(n^2)$.